

Reliable AI Assignment 3

2022480011 인공지능학과 엄준혁

1. 제공되는 모델의 유형

- .onnx : 표준
Protocol Buffers (Protobuf) 기반의 이진 파일 형태로 저장됨
합성곱 신경망(CNN), 순환 신경망(RNN), 트랜스포머(Transformer) 등 다양한 아키텍처 지원
- .nnet : 레거시 지원형식
일반 텍스트 파일 형태로 저장되어 바로 읽을 수 있음
단순한 완전 연결 신경망을 표현하는데 특화되어 있음
다양한 활성화함수의 표현은 제한됨
- .pb : 현재 Marabou에서는 지원하지 않음

2. 포함된 데이터셋

- ACAS XU : 항공기 충돌 회피 시스템 검증
입력형식 : 물리적 센서 측정값. 거리, 각도, 속도 등 5개 입력
검증속성 : 안전성. Ex) 입력조건 하에 모델이 "경로유지"를 지시할 가능성이 있는가?
예시쿼리 :
 $x_0 \geq 0.6$
 $x_0 \leq 0.6798577687$
 $x_1 \geq -0.5$
 $x_1 \leq 0.5$
 $x_2 \geq -0.5$
 $x_2 \leq 0.5$
 $x_3 \geq 0.45$
 $x_3 \leq 0.5$
 $x_4 \geq -0.5$
 $x_4 \leq -0.45$
 $y_0 \geq 3.9911256459$
- CollisionAvoidance(COAV) : 일반 충돌 회피속성 검증
입력형식 : 2차원 평면상의 운동학적 상태. 차량 좌표, 속도, 장애물과의 상대거리 등
검증속성 : 안전성. Ex) 장애물이 근방에 있을 때 현재 조향각도, 출력등이 안전범위인가?
예시쿼리 :
 $y_0 \leq 0$

- TwinStreams(Twin) : 여러 개의 복합 신경망 검증

입력형식 : 두 개의 개별적인 입력 벡터

검증속성 : 여러 개의 네트워크에 작은 마진을 둔 두 개의 벡터를 입력하여 출력을 통해 동등성, 강건성 등을 검증.

예시쿼리 :

$y_0 \leq 0$

- MNIST : 이미지(흑백) 분류 검증

입력형식 : 0~9까지의 손글씨 숫자 흑백 이미지 데이터셋. 28 X 28 크기의 이미지.

검증속성 : local robustness. 특정 이미지 x 에 대한 L_∞ norm ϵ 근방에서 강건성 검증.

예시쿼리 :

$x_0 \geq -0.1$

$x_0 \leq 0.1$

$x_1 \geq -0.1$

$x_1 \leq 0.1$

$x_2 \geq -0.1$

...

$x_{782} \leq 0.1$

$x_{783} \geq -0.1$

$x_{783} \leq 0.1$

$+y_0 -y_1 \leq 0$

$+y_2 -y_1 \leq 0$

$+y_3 -y_1 \leq 0$

$+y_4 -y_1 \leq 0$

$+y_5 -y_1 \leq 0$

$+y_6 -y_1 \leq 0$

$+y_7 -y_1 \leq 0$

$+y_8 -y_1 \leq 0$

$+y_9 -y_1 \leq 0$

- CIFAR10 : 이미지(컬러) 분류 검증

입력형식 : 자동차, 새 등 10개 클래스의 컬러 이미지 데이터셋. 32 X 32 X 3 크기의 이미지.

검증속성 : MNIST와 마찬가지로 적대적 공격에 대한 강건성 검증.

예시쿼리 : Github에 별도로 마련된 검증파일은 존재하지 않음.

사용자가 추가적으로 정의 필요

3. 데이터셋/모델/검증쿼리

- **데이터셋** : Iris dataset.

붓꽃의 종(Setosa, Versicolour, Virginica)을 분류하는 머신러닝 데이터셋.

꽃받침의 길이와 너비, 꽃잎의 길이와 너비라는 총 4개의 수치형 입력 변수를 가짐.

- **모델** : MLP

Marabou와의 호환성을 고려하여 PyTorch로 설계하고 ONNX 포맷으로 변환하였음.

Input Layer: 4개 노드 (Iris 특성)

Hidden Layer: 8개 노드, ReLU 활성화 함수 사용

Output Layer: 3개 노드 (클래스별 Logit 값 추출)

Optimizer : Adam

Epoch : 10

Learning rate : 0.01

- **검증쿼리** : 특정 입력에 대한 모델의 Local Robustness를 검증하는 쿼리를 구성.

입력제약) x_{base} 를 중심으로 L_∞ 반경 ϵ 내의 구역을 탐색 범위로 설정함.

$$\|x' - x_{base}\|_\infty \leq \epsilon,$$

$$x_{(base,i)} - \epsilon \leq x'_i \leq x_{(base,i)} + \epsilon \text{ for all input feature } i$$

출력제약) 입력 범위내의 모든 x' 에 대해 모델 f 의 예측 클래스가 x_{base} 의 예측 클래스와 동일해야하므로, 따라서 반례는 다음과 같이 표현할 수 있다.

$$\exists x' \in \text{Input Region} \text{ s.t. } f(x')_{other} \geq f(x')_{base}$$

즉 기존 입력이 예측하지 않았던 클래스의 로짓값이 기존 입력이 예측한 로짓값보다 큰 경우가 생기면 SAT이며, 이는 모델의 강건성이 깨졌음을 의미한다. 반대로 이러한 경우가 존재하지 않음이 증명되면 UNSAT이며, 이는 모델이 해당 범위 내에서 강건함을 의미한다.

4. 결과분석

다음은 노이즈 반경 ϵ 을 변화시키며 Iris dataset의 첫번째 샘플에서 검증을 수행한 결과이다.

ϵ	결과	소요시간(s)	사용변수	사용방정식
0.05	UNSAT	0.0024	12	23
0.1	UNSAT	0.0031	12	23
0.3	UNSAT	0.0024	12	23
0.5	UNSAT	0.0024	12	23
0.8	SAT	0.0025	19	27
1.0	SAT	0.0025	20	28

*사용변수와 방정식의 개수는 Solver 내부의 preprocessing을 거친 이후의 값이다.

ϵ 값이 증가하다가 임계값인 0.8을 넘는 순간 사용한 변수와 방정식의 숫자가 증가함을 확인할 수 있었다. 이는 학습한 MLP 모델이 0.5~0.8 사이의 노이즈 마진을 가지고 있었으며, 변수와 방정식의 수가 증가한 것은 입력범위가 증가함에 따라 뉴런의 활성화 상태를 표현하기 위한 변수가 증가한것으로 해석이 가능하다.

또한 단일 샘플에 대한 검증 시간은 0.002~0.003s

첫번째 샘플 값 : [5.1 3.5 1.4 0.2]

각 ϵ 에 대한 적대적 반례

- $\epsilon = 0.8$: [4.3, 4.3, 0.6, -0.6]
- $\epsilon = 1.0$: [4.1, 4.1, 0.4, -0.8]

5. 논의

Marabou의 강점 (Strengths)

- 수학적 엄밀성 (Formal Guarantee): 일반적인 테스트(Testing)는 무한한 입력 공간 중 일부 샘플만을 확인하지만, Marabou는 SMT 솔버를 통해 주어진 L_∞ 범위 ϵ 내의 모든 입력에 대해 오답이 없음을 수학적으로 증명(UNSAT)할 수 있다는 점에서 강력한 신뢰성을 제공한다.
- 전처리 최적화 : 실험 결과에서 확인했듯, Marabou는 Bound Tightening 기법을 통해 불필요한 뉴런의 상태를 고정함으로써 탐색 공간을 획기적으로 줄인다. 비록 소형 MLP 모델이었지만 0.003초 내외의 매우 빠른 속도로 결과를 도출하는 것을 확인할 수 있었다.

한계점 및 개선 방향 (Limitations)

- 확장성 문제 (Scalability): ϵ 값이 커질수록 전처리 후 방정식과 변수의 개수가 급격히 증가하는 것을 관찰했다. 이는 활성화 함수(ReLU)의 상태를 확정할 수 없는 '불확실한 뉴런'이 많아질수록 계산 복잡도가 기하급수적으로 늘어남을 의미하며, 대규모 ResNet 등 깊은 모델에 적용하기에는 한계가 있을 것으로 판단된다.
- 물리적 제약 조건의 부재: 적대적 반례 분석 결과, 꽃잎의 너비가 음수(-0.8)인 비현실적인 입력값이 도출되었다. Marabou는 모델의 수학적 허점은 잘 찾아내지만, 데이터의 도메인 지식(예: 길이는 양수여야 함)은 알지 못한다. 따라서 더 유의미한 검증을 위해서는 입력 제약 조건에 물리적 하한선(0 이상 등)을 명시적으로 추가하는 과정이 필요하다.